

365 defects across 100 pages. 75% were structure, not misread letters.

Running heads swallowed into the body text. Footnotes merged into the paragraph above them. Page numbers left sitting inline.

So I stopped asking the model to read the page, and started asking for an ordered sequence of typed blocks with footnote anchors.

running head

الدفاع الأول

body paragraph

يميني حتى أضع أعداءك موطئاً لقدميك. عصا قوة يرسل لك الرب من اورشليم. وتسود في وسط أعدائك. معك الرئاسة في يوم قوتك في بهاء قدسيك، من البطن قبل كوكب الصبح ولدتك (مز ١٠٩: ١ - ٣). ونلاحظ أن عبارة "عصا قوة يرسل لك الرب من اورشليم" هي نبوة عن قوة التعليم الذي خرج به الرسل من اورشليم للكراسة في كل مكان. وعلى الرغم من أنه قد حُكم بالموت على كل من يكرز أو حتى يعترف باسم المسيح، إلا أننا نقبل هذا الاسم ونعلم به في كل مكان. ولكن إذا كنتم أنتم أيضاً تقرأون هذه الكلمات بفكر معادٍ فلن تستطيعوا أن تفعلوا شيئاً أكثر من قتلنا كما قلنا من قبل، لكن هذا لن يضرنا بل سيأتي بالعقاب الأبدي بالنار عليكم وعلى كل من يعادينا ظلماً ويظل بدون توبة.

الفصل السادس والأربعون

heading, in flow

body paragraph

ولئلا يقول البعض بغير وجه حق **footnote anchor ١٣٨** عن تعليمنا . إننا نؤكد أن المسيح قد وُلد منذ مئة وخمسين عاماً **١٣٨** في أيام كيرينايوس ثم في أيام بيلاطس البنطي علم بما نقوله نحن الآن عنه، ويهتموننا كما لو كنا نقول! إن كل الناس الذين ولدوا قبل مجيء **footnote anchor ١٣٩** عن أفعالهم، وسوف نرد على هذه المشكلة **١٣٩**. لقد تعلمنا أن المسيح هو بكر الله، وشرحنا قبلاً أنه هو الحكمة (لوغوس، Logos) الذي فيه يشترك كل البشر. والذين

footnote apparatus

<sup>١٣٨</sup> ربما يستخدم ق. يوستينوس هنا أرقاماً تقريبية وإلا فيجب أن يكون تاريخ كتابة هذا الدفاع على أقصى تقدير في عام ١٤٧م، ولكن فيلكس والي الاسكندرية (المذكور في فصل ٢٩) تم تحديده على أنه موناكيوس فيلكس والي الإسكندرية في الفترة من ١٤٨ - ١٥٤م، ولذا فإن هذا الدفاع لا بد وأن يكون قد كُتب بعد عام ١٤٧.

<sup>١٣٩</sup> في هذه الفقرة يناقش ق. يوستينوس التساؤل عن كيفية محاسبة من عاشوا قبل مجيء المسيح، وهو يجيب على ذلك بالإشارة إلى أن الابن مولود أزلياً.

printed page number

٧٣

THE ANSWER

5 of them cannot be separated on this evidence. They span 22x in price.

8 clear every gate; the top 5 cannot be separated on the 8 hand-verified pages. Score, then the price for a 461-page book.

|   |                                |       |         |
|---|--------------------------------|-------|---------|
| ● | Gemini 3.7 Flash               | 99.9% | \$0.32  |
| ● | Gemini 3.8 Flash               | 99.6% | \$2.34* |
| ● | Gemini 3.5 Flash               | 98.8% | \$0.32  |
| ● | Claude Sonnet 5                | 98.8% | \$6.99  |
| ● | Qwen 3.8 Max                   | 98.7% | \$3.81  |
| ● | Gemini 3.8 Flash, thinking off | 98.2% | \$2.31* |
| ● | GPT 5.6 Terra                  | 96.7% | \$5.07  |
| ● | Kimi K3                        | 96.2% | \$7.11  |

When accuracy ties, the answer is cost.

\* rate derived from metered billing, not a published price

The model I was already shipping on was the wrong one.

Gemini 2.5 Flash places every footnote anchor correctly, then misreads the prose.

|            |              |                                          |
|------------|--------------|------------------------------------------|
| task score | <b>87.5%</b> | body accuracy 0.879, under the 0.95 gate |
|------------|--------------|------------------------------------------|

|                  |               |                                  |
|------------------|---------------|----------------------------------|
| price, 461 pages | <b>\$1.19</b> | 3.7× what Gemini 3.5 Flash costs |
|------------------|---------------|----------------------------------|

|                   |              |            |
|-------------------|--------------|------------|
| that model scores | <b>98.8%</b> | for \$0.32 |
|-------------------|--------------|------------|

Older and cheaper are not the same thing.

# Enough to rule models out. Not enough to crown a winner.

- 8 pages verified by hand, not 20. The top 5 sit inside each other's confidence bands.
- One book, one publisher's typography, one script.
- One run per model. No repeats, so no variance estimate.
- The other 12 pages measure agreement between models, which is not accuracy and cannot rank anything.

**The gates and the weights were fixed before I read a single score.**